

# Equipe Pandora

Iago Magalhães e Vanessa Carvalho

# Tópicos

**1** Motivação do trabalho

**2** Introdução

**3** Objetivos

**4** Materiais e Métodos

**5** Metodologia


**6** Resultados

**7** Conclusão



# Motivação do trabalho

Este trabalho visa desenvolver uma solução para correção automática de provas e simulados de múltipla escolha tem como propósito simplificar e otimizar o procedimento de avaliação acadêmica em contextos educacionais, com o intuito de atender às demandas de educadores, professores e instituições de ensino.

The background features abstract organic shapes in two shades of green and a thin orange line. A large, light green shape occupies the right side and bottom. A darker green shape is in the top left. A thin orange line forms a loop on the left side.

# Introdução

Neste trabalho buscamos testar arquiteturas de redes neurais convolucionais que melhor se adaptassem ao dataset disponibilizado pela equipe do Hackathon. Após a seleção do melhor modelo, será desenvolvida uma API para utilização da melhor rede para correção automática de provas e simulados.

The background features abstract organic shapes in two shades of green and a thin orange line. A large, light green shape occupies the right side and bottom. A darker green shape is in the top left. A thin orange line forms a wavy shape on the left side.

# Objetivos

Objetivo Geral:

Analisar o uso de redes convolucionais no auxílio de leitura de cartões respostas;



## Objetivo Específicos:

- Criar um detector de respostas com Deep Learning;
- Analisar desempenho de arquiteturas de CNN;
- Desenvolver uma API para analisar imagens de provas diversas.

The background features abstract organic shapes in shades of green and orange. A large, light green shape occupies the right side and bottom, while a darker green shape is at the top left. A thin orange line curves along the left edge.

# Materiais e Métodos

## Dataset:

O dataset utilizado para o treino das CNN's foi disponibilizado pela equipe organizadora do Hackathon. Para fins da utilização, tratamento e treino das redes, foi optado por realizar o download dos arquivos no formato 'Pascal VOC XML'. Ao todo são 209 imagens divididas em três conjuntos, sendo treino, teste e validação.

Pré-processamento:

Filtros
Dilatação
Filtro Laplaciano
Filtro Gaussiano
Filtro de Média
Filtro de Mediana
Filtro de Mediana + Binarização
Filtro Gaussiano + Binarização
Filtro de Mediana + Filtro Gaussiano
Filtro de Mediana + Filtro Sobel
Filtro Gaussiano + Canny

## Métricas de avaliação:

Para avaliar os resultados obtidos pelas redes convolucionais, são utilizadas métricas estatísticas comumente utilizadas pela comunidade. Neste trabalho as métricas de acurácia e precisão foram utilizadas com fator de seleção do melhor modelo de classificação.

$$\textit{Acurácia} = \frac{VP+VN}{VP+VN+FP+FN}$$

$$\textit{Precisão} = \frac{VP}{VP+FP}$$

## Redes utilizadas:

Para se desenvolver o classificador, optamos por utilizar redes conhecidas pela comunidade, visando a facilidade de implementação, rapidez no desenvolvimento e utilizando seus resultados anteriores como base para o desenvolvimento de uma solução para o problema.

Redes CNN's
AlexNet
EfficientNetB0
InceptionV3
LeNet

The background features abstract organic shapes in two shades of green and a thin orange line. A large, light green shape occupies the right side and bottom. A darker green shape is in the top left. A thin orange line curves along the left edge.

# Metodologia

A metodologia abordada foi baseada em trabalhos acadêmicos sobre treino de redes convolucionais. O primeiro passo foi organizar o banco de dados em treino, teste e validação visando problemas clássicos como sobreajuste e subajuste. Além disso, foi optado por realizar o pré-processamento das imagens para realizar o aguçamento de características da imagem. Logo depois, foi realizado o treinamento das quatro redes CNN's, seguindo os mesmos padrões, tais como, 1000 épocas de treinamento e otimizador Adam. Para seleção do melhor modelo foi levado em conta as métricas de acurácia e precisão.

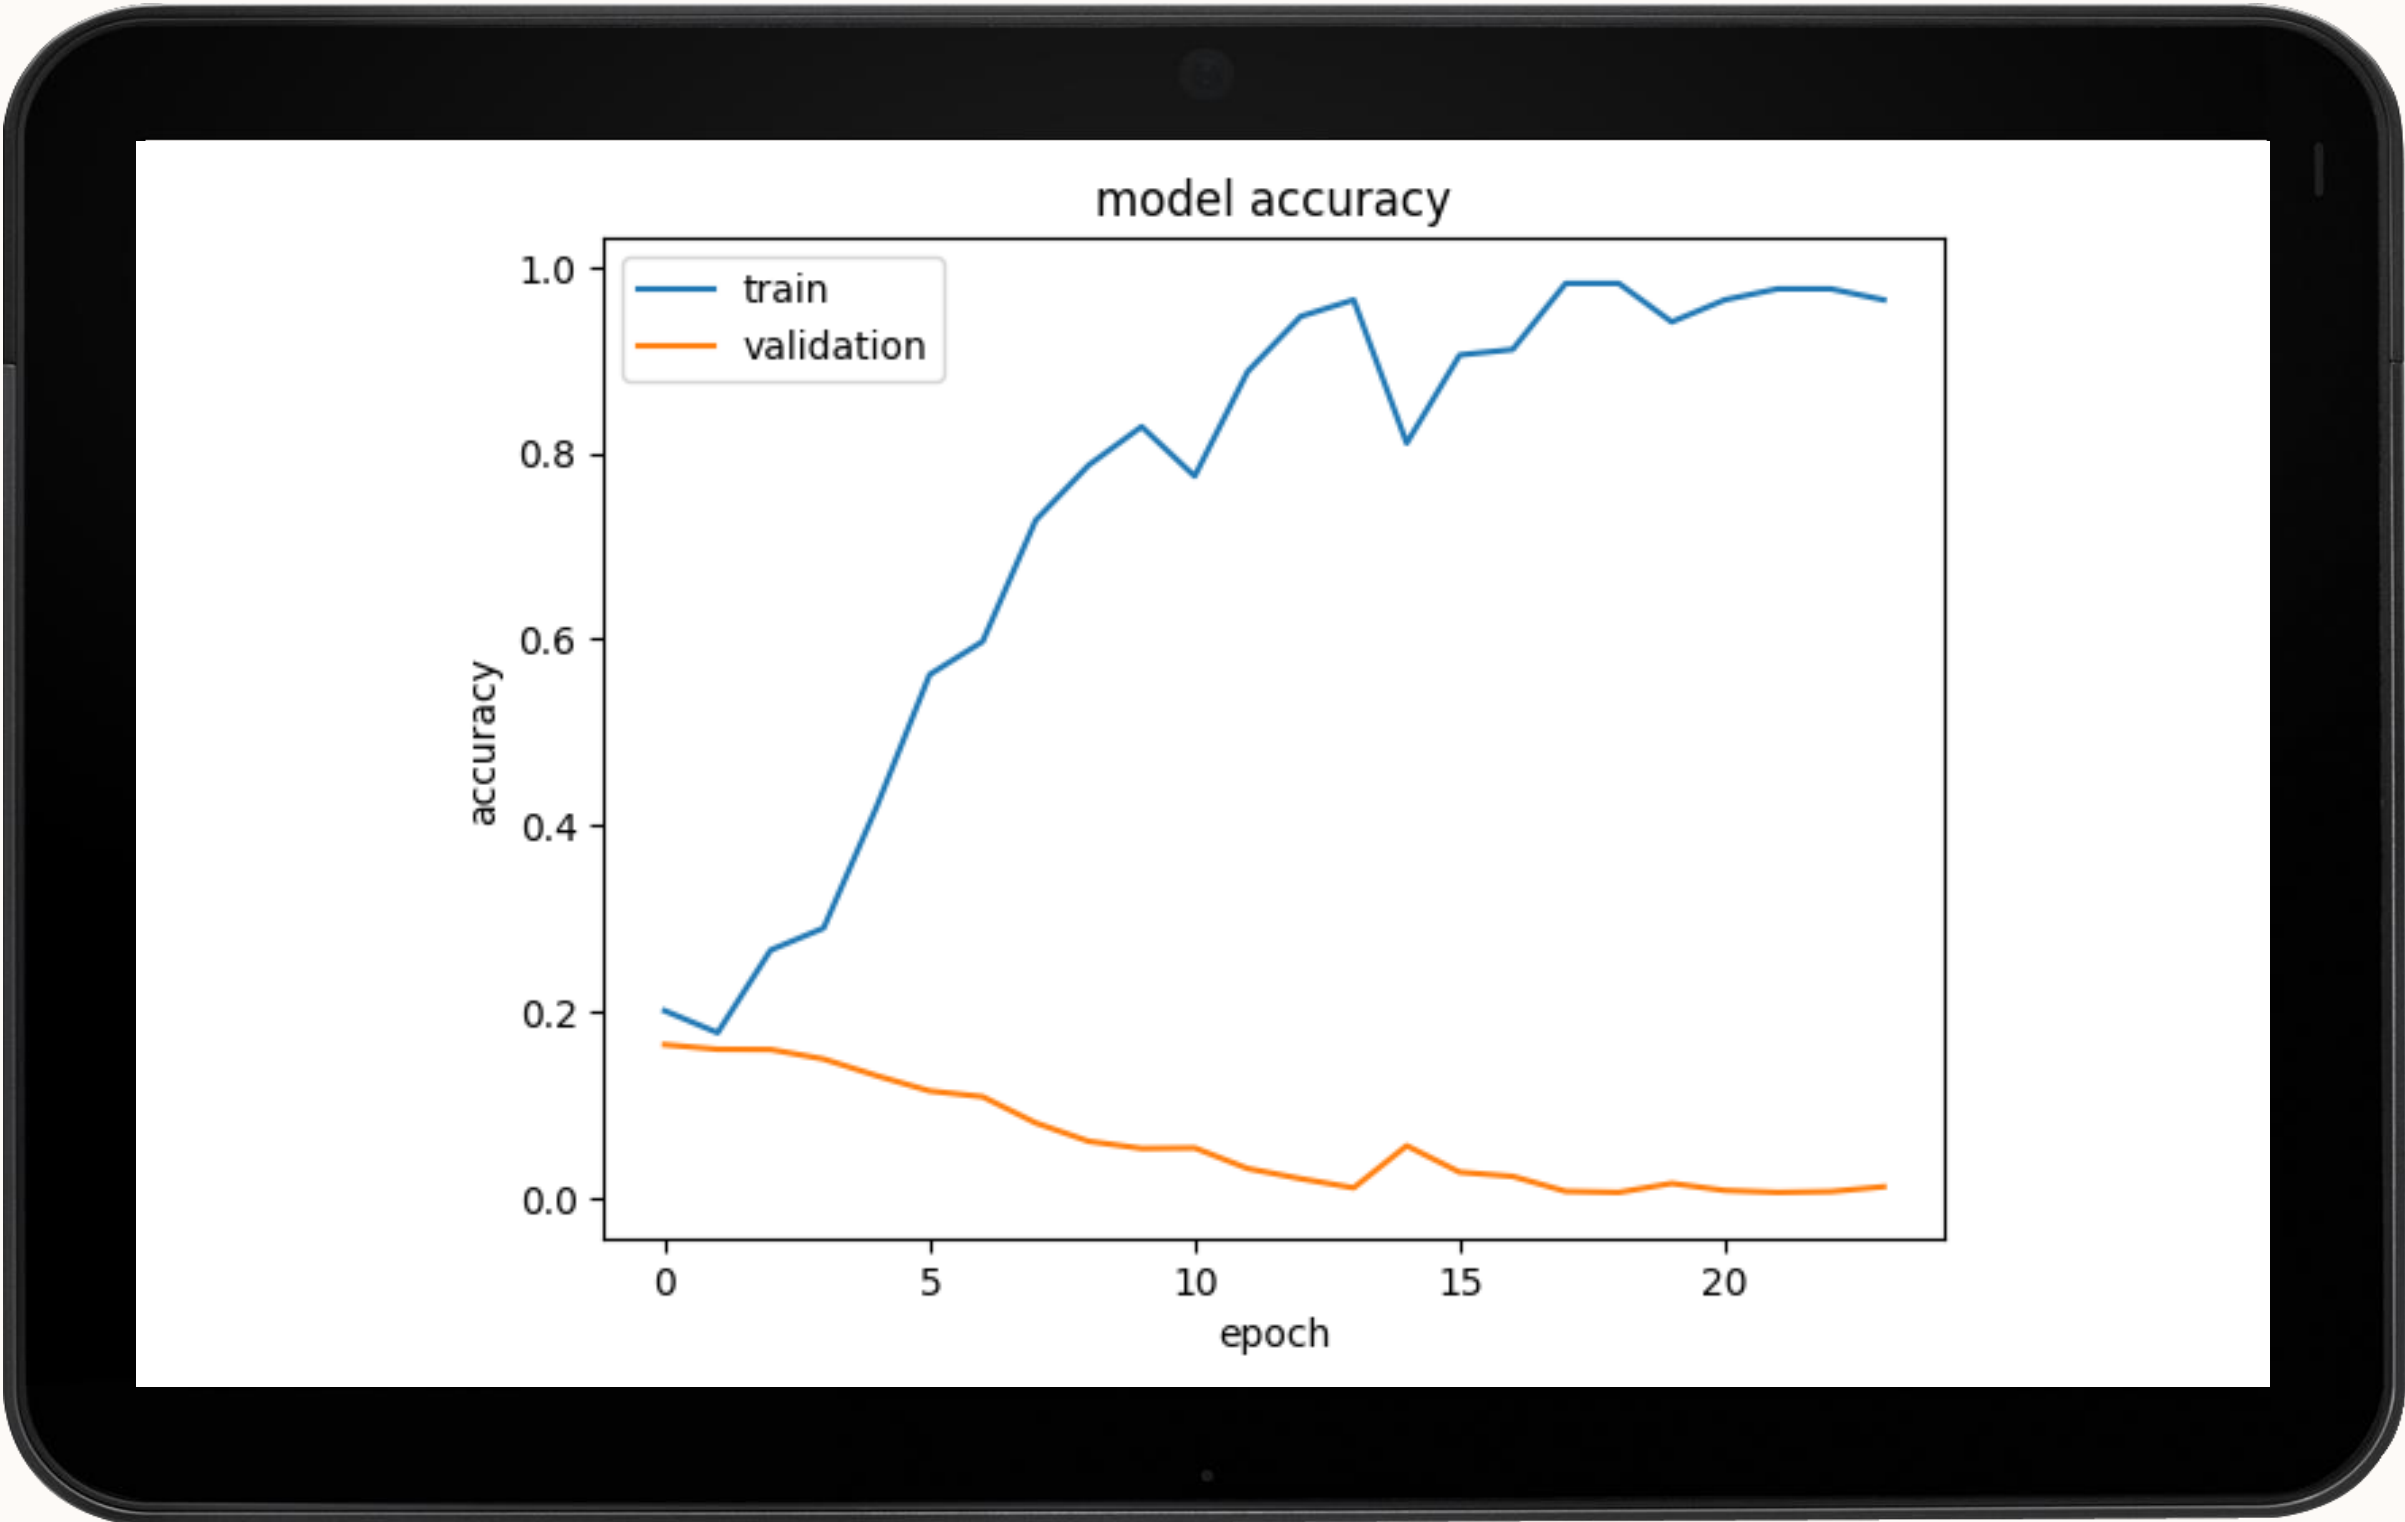




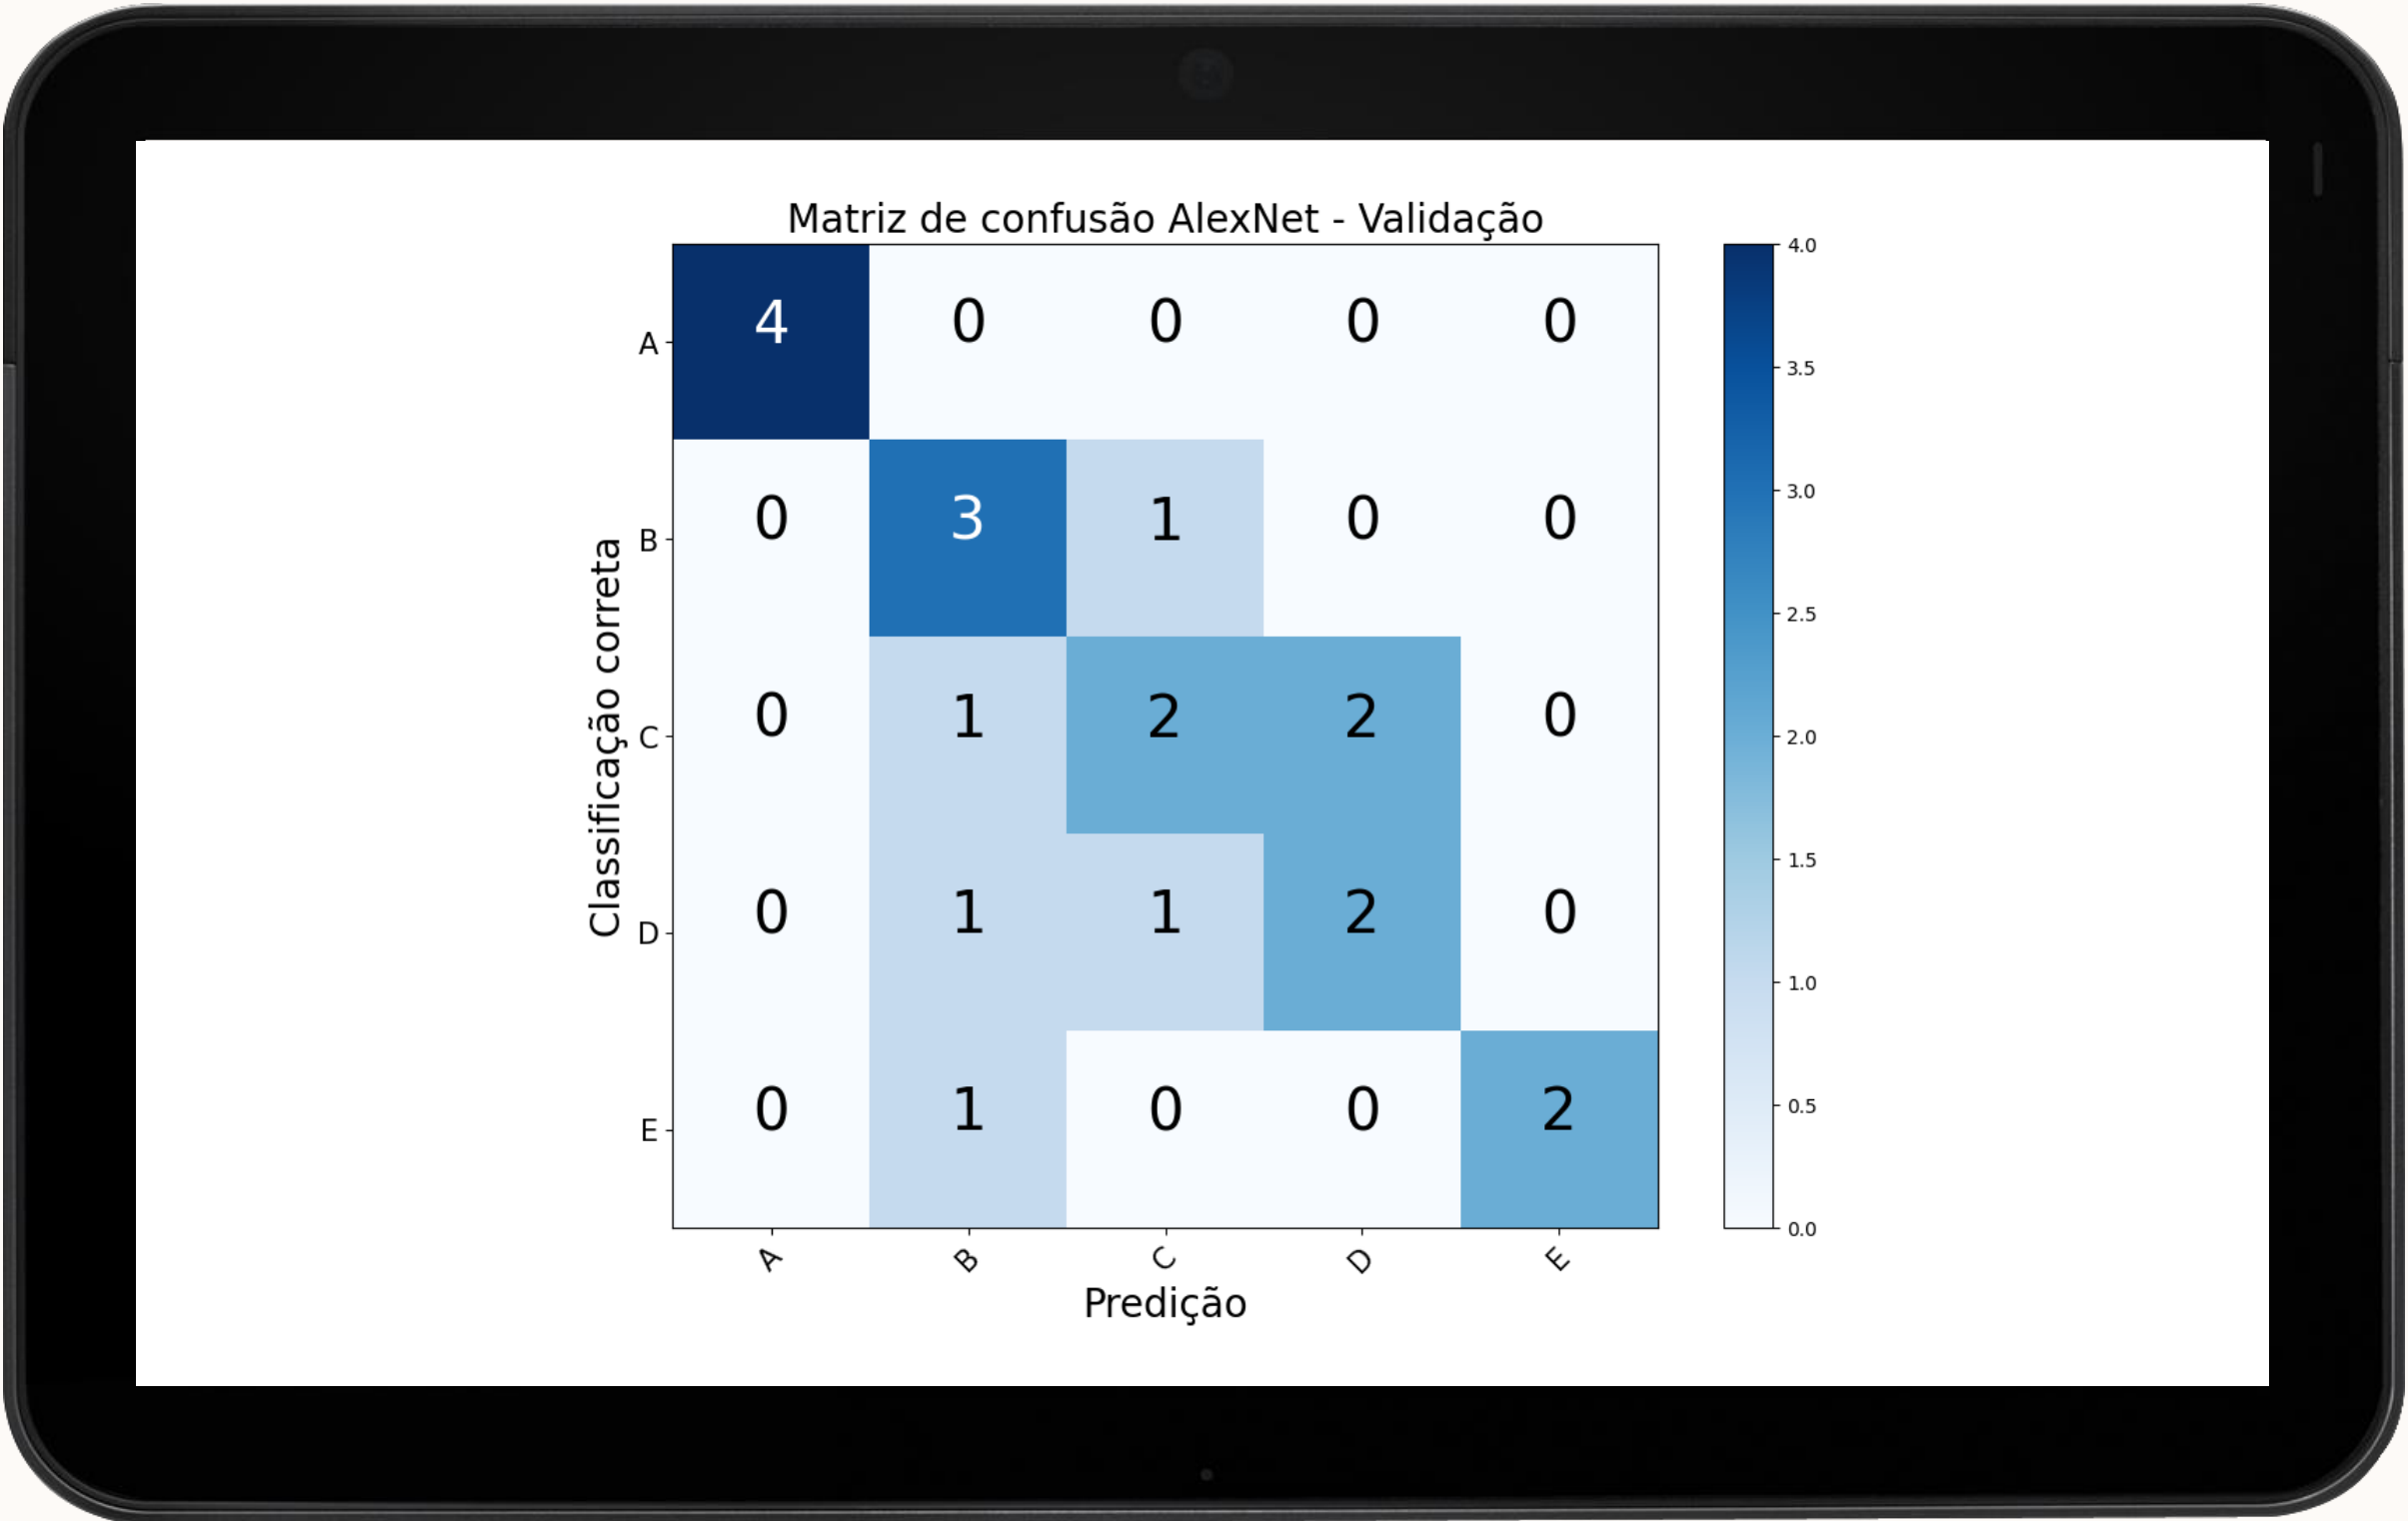
# Resultados

Os resultados obtidos para cada rede podem ser visualizados a seguir. Vale ressaltar que entre os 10 pré-processamentos utilizados, o melhor em todos os modelos foi 'Filtro Gaussiano + Binarização'.

AlexNet:



AlexNet:

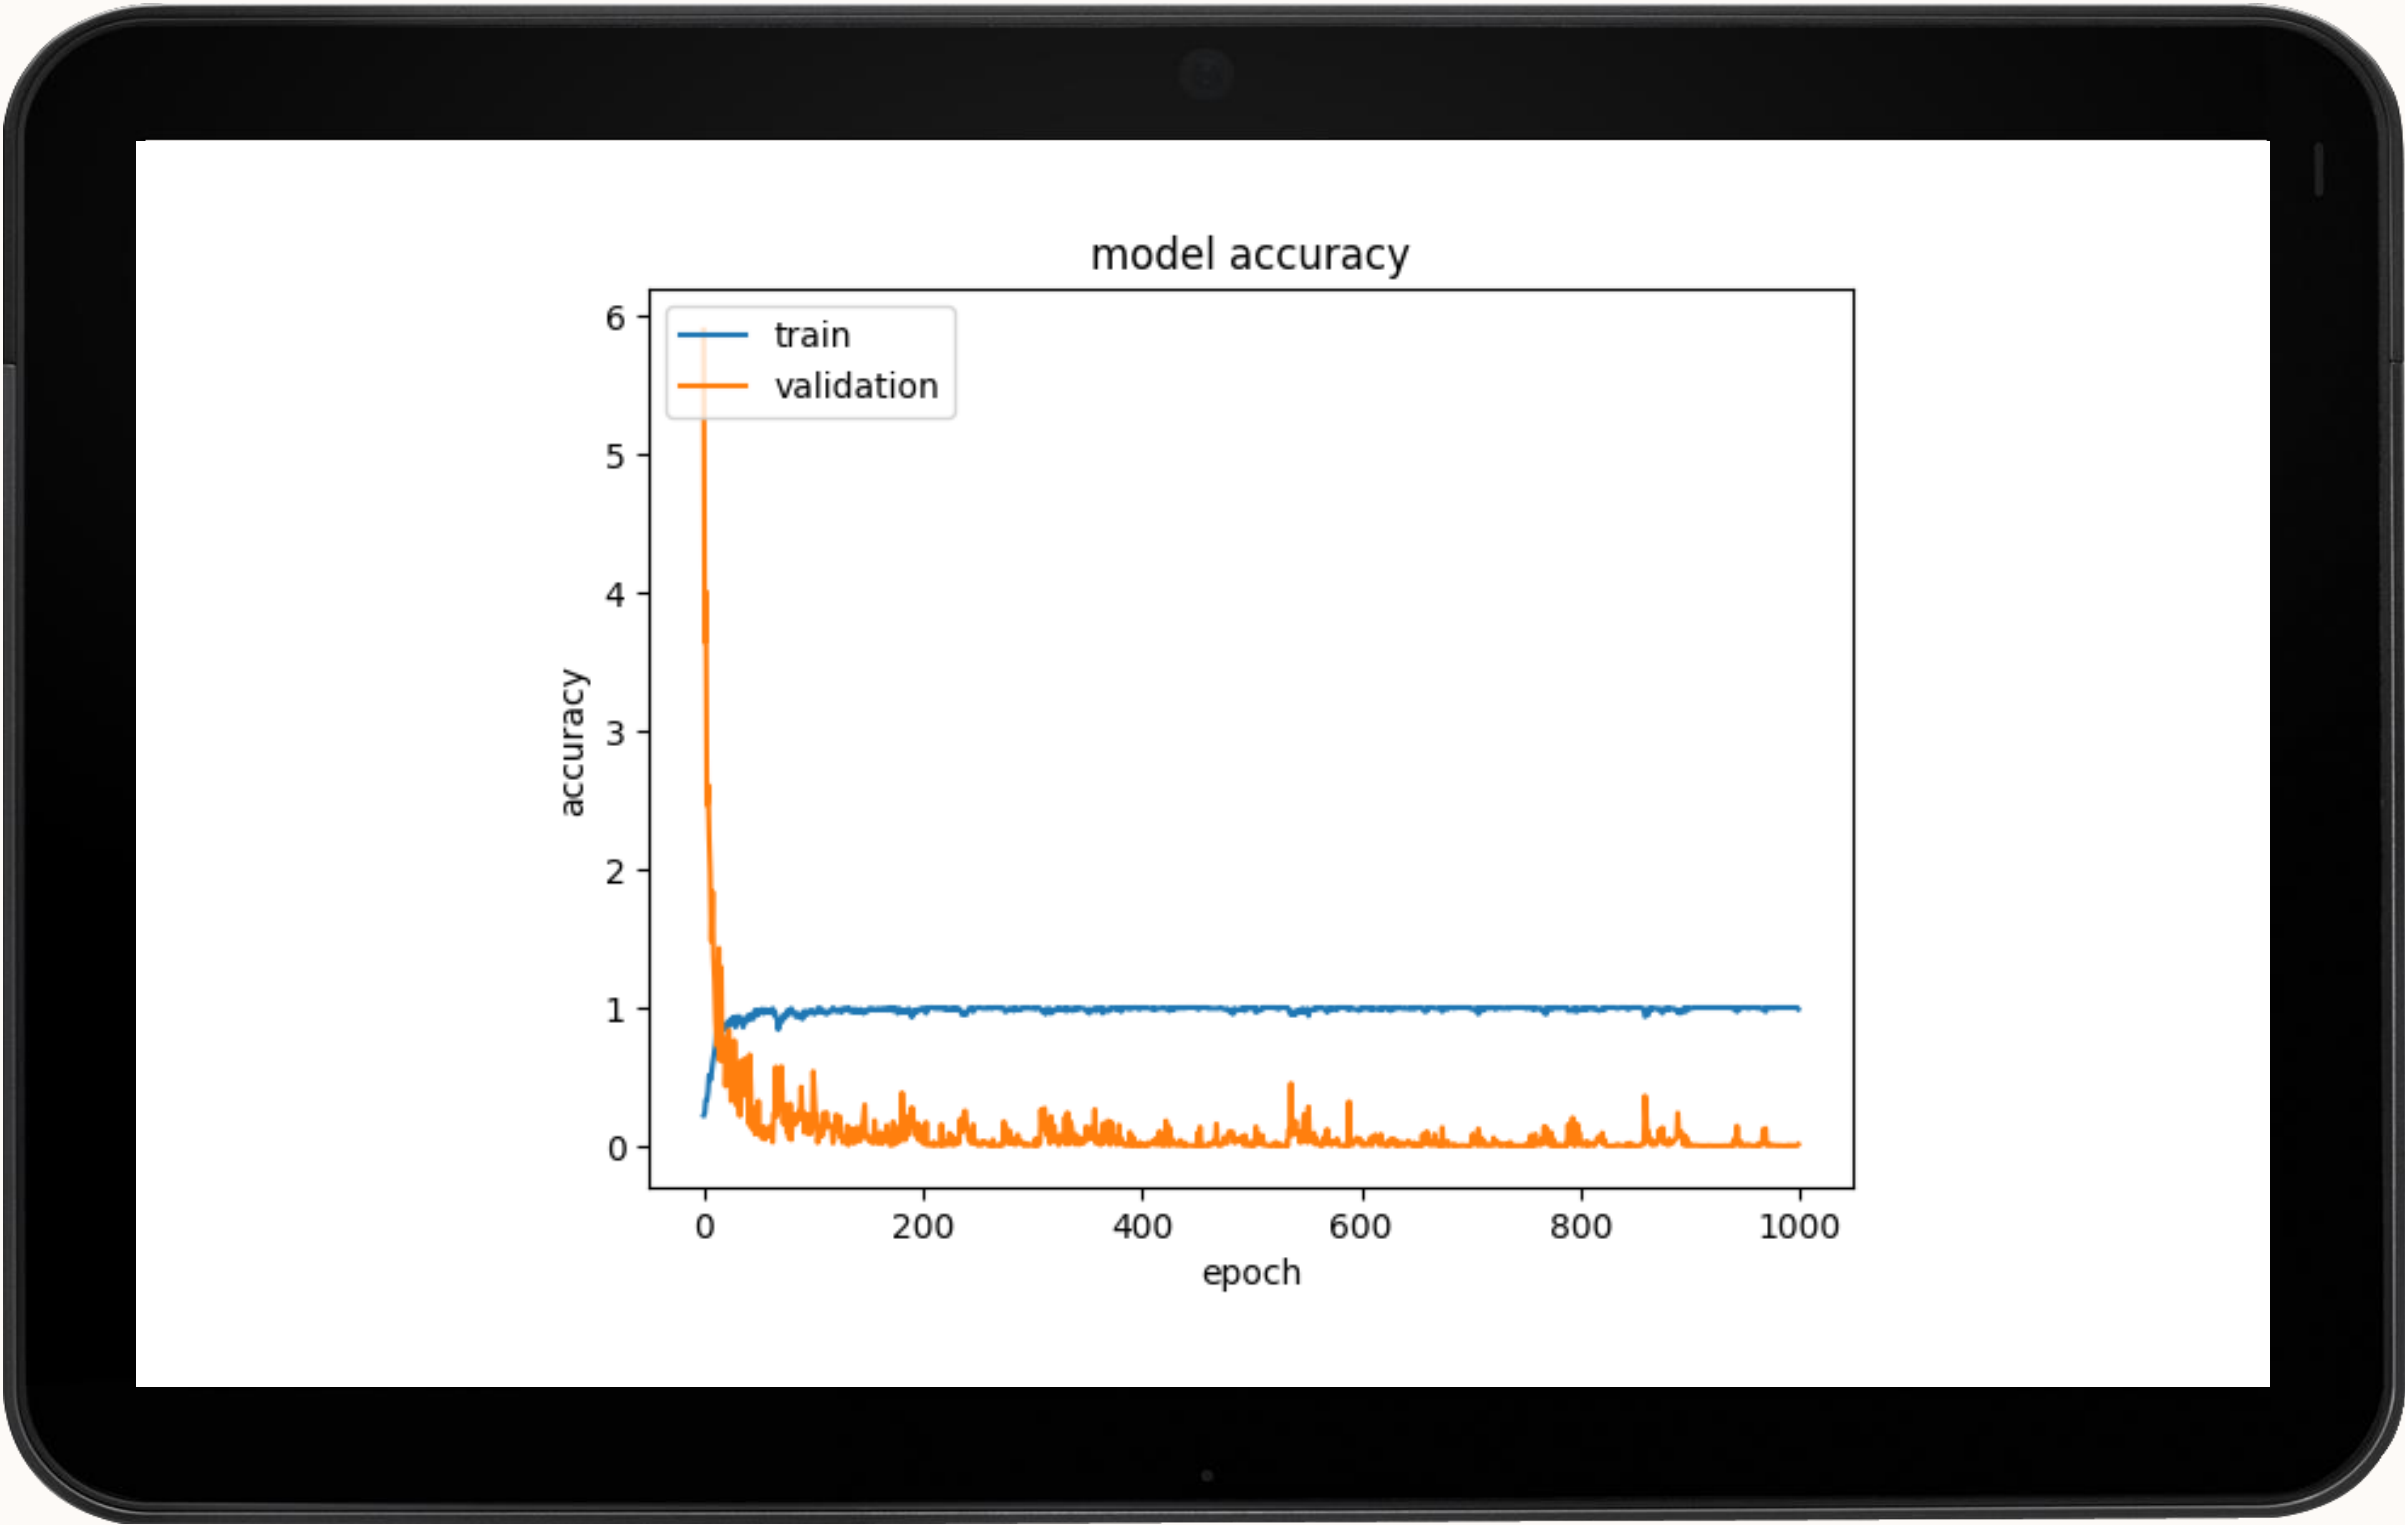


AlexNet:

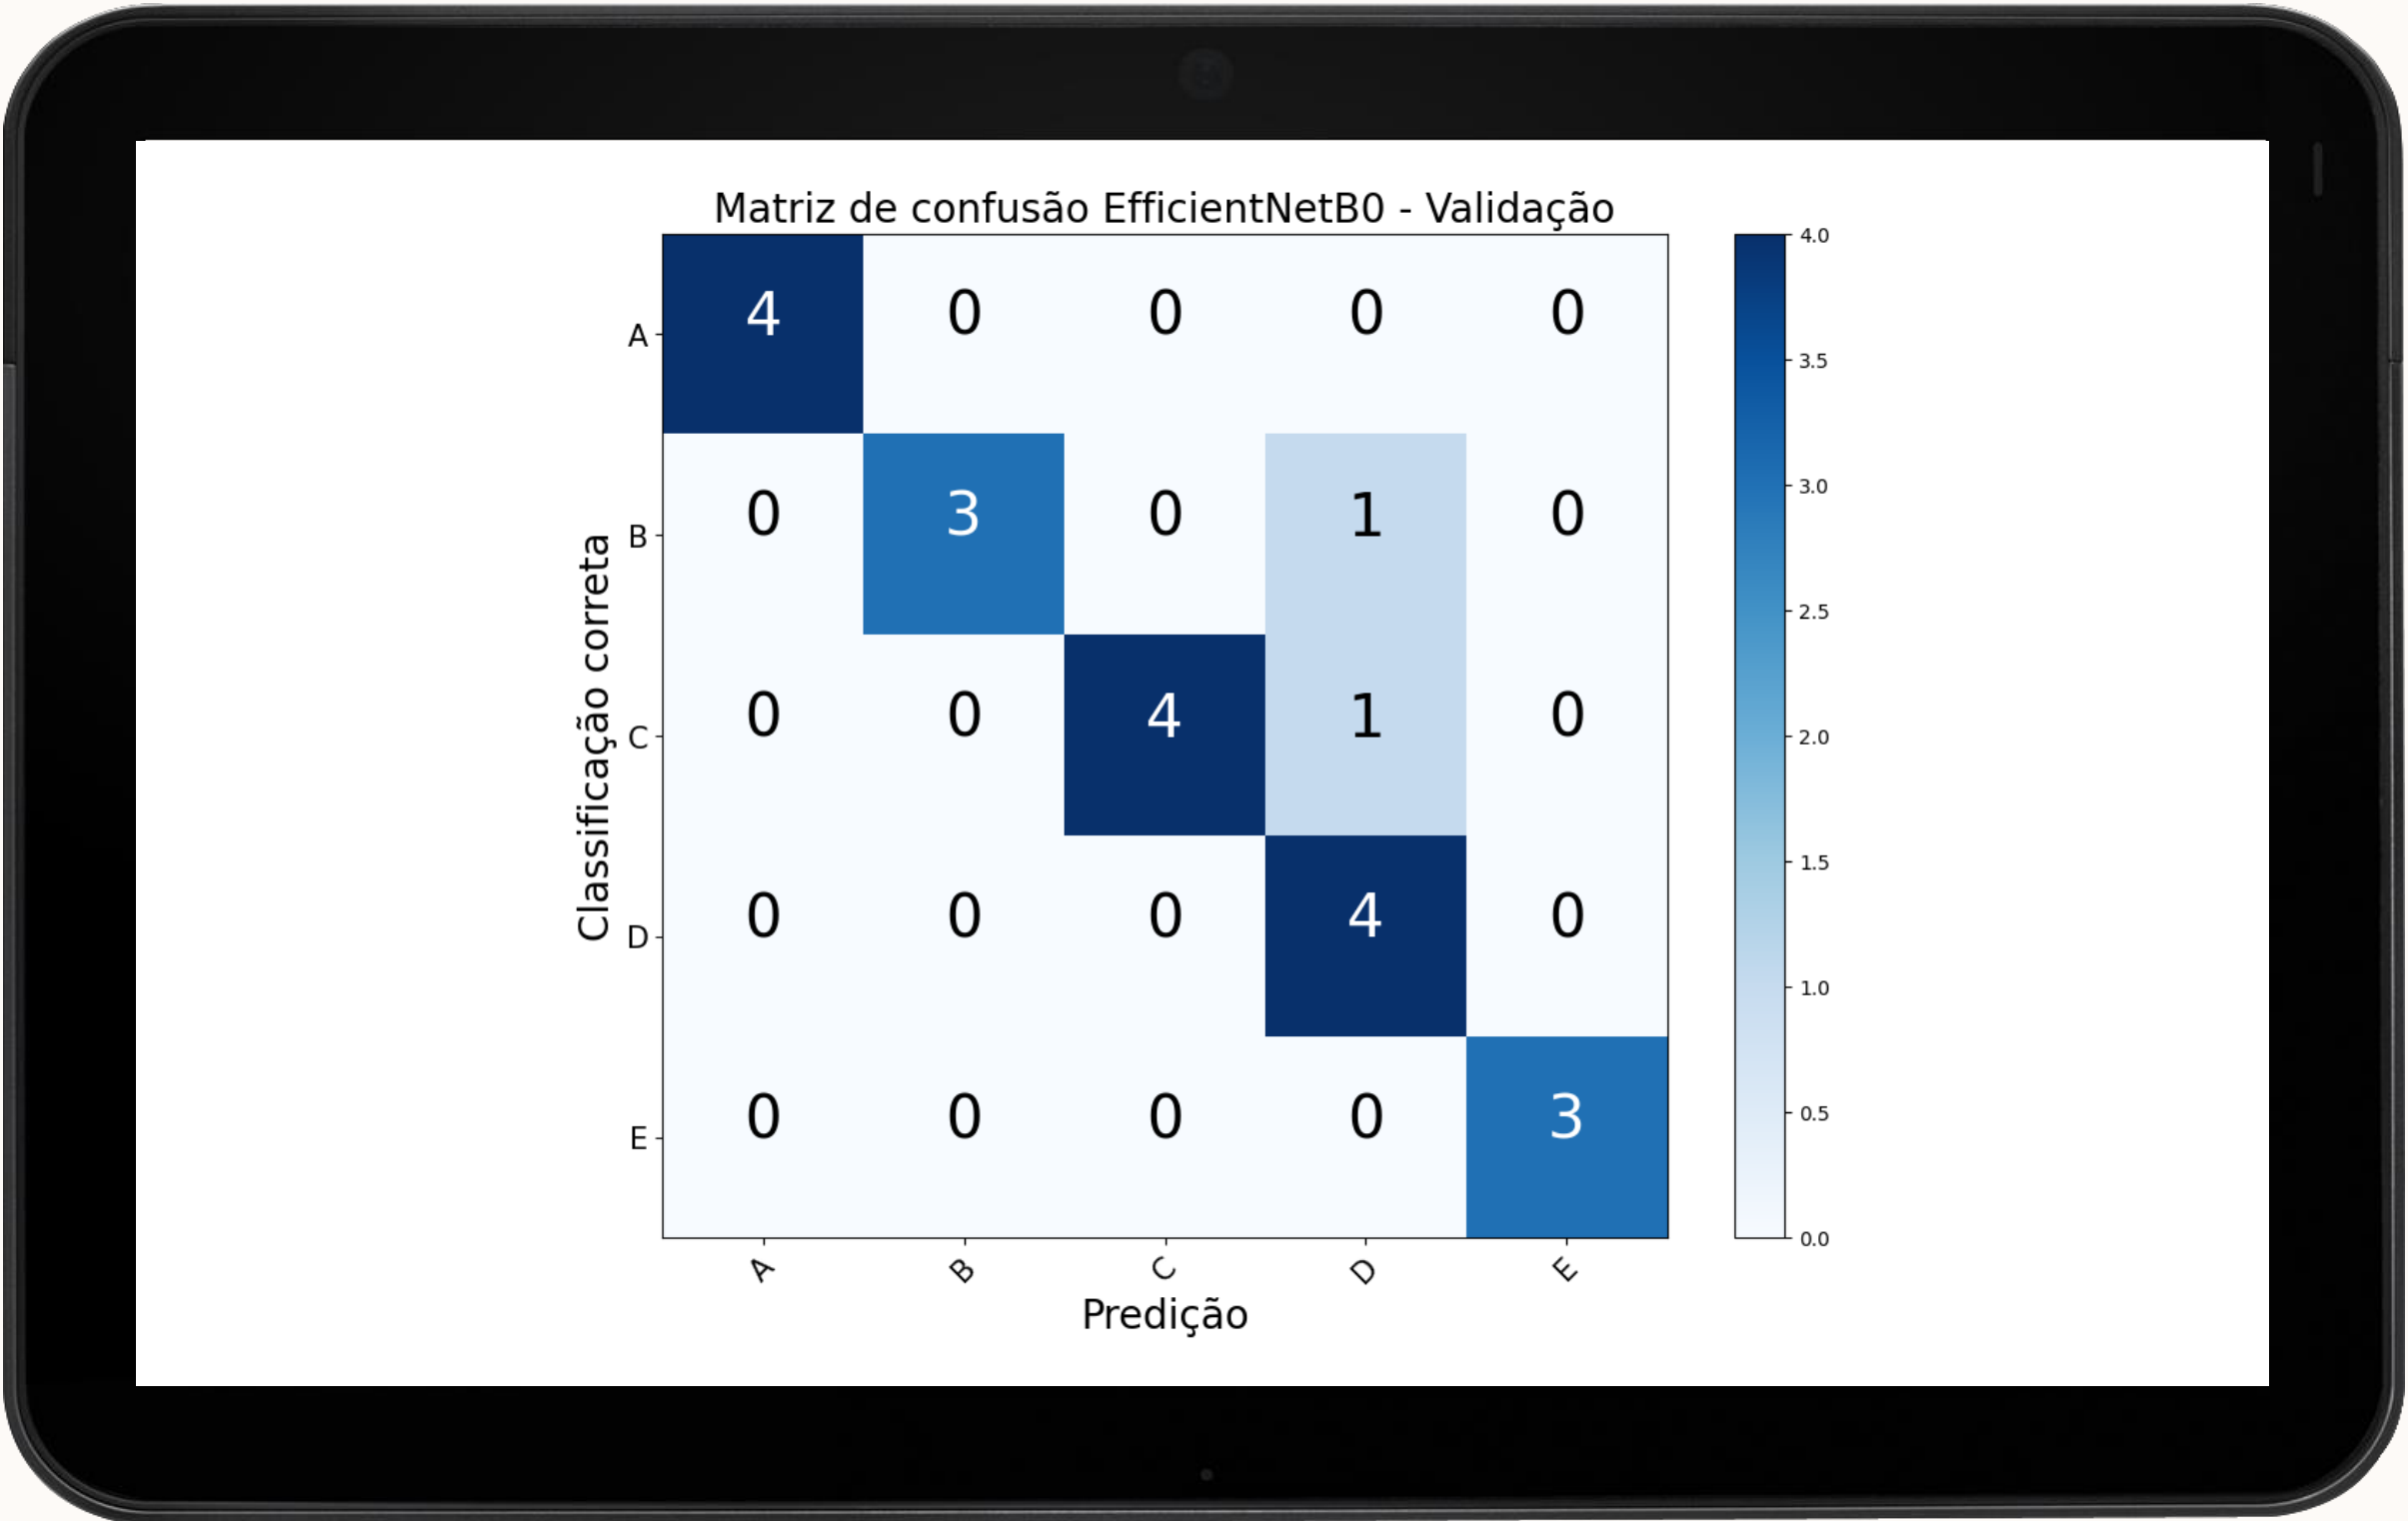
Acurácia: 65%

Precisão: 70%

EfficientNetB0:



EfficientNetB0 :




EfficientNetB0 :

Acurácia: 90%

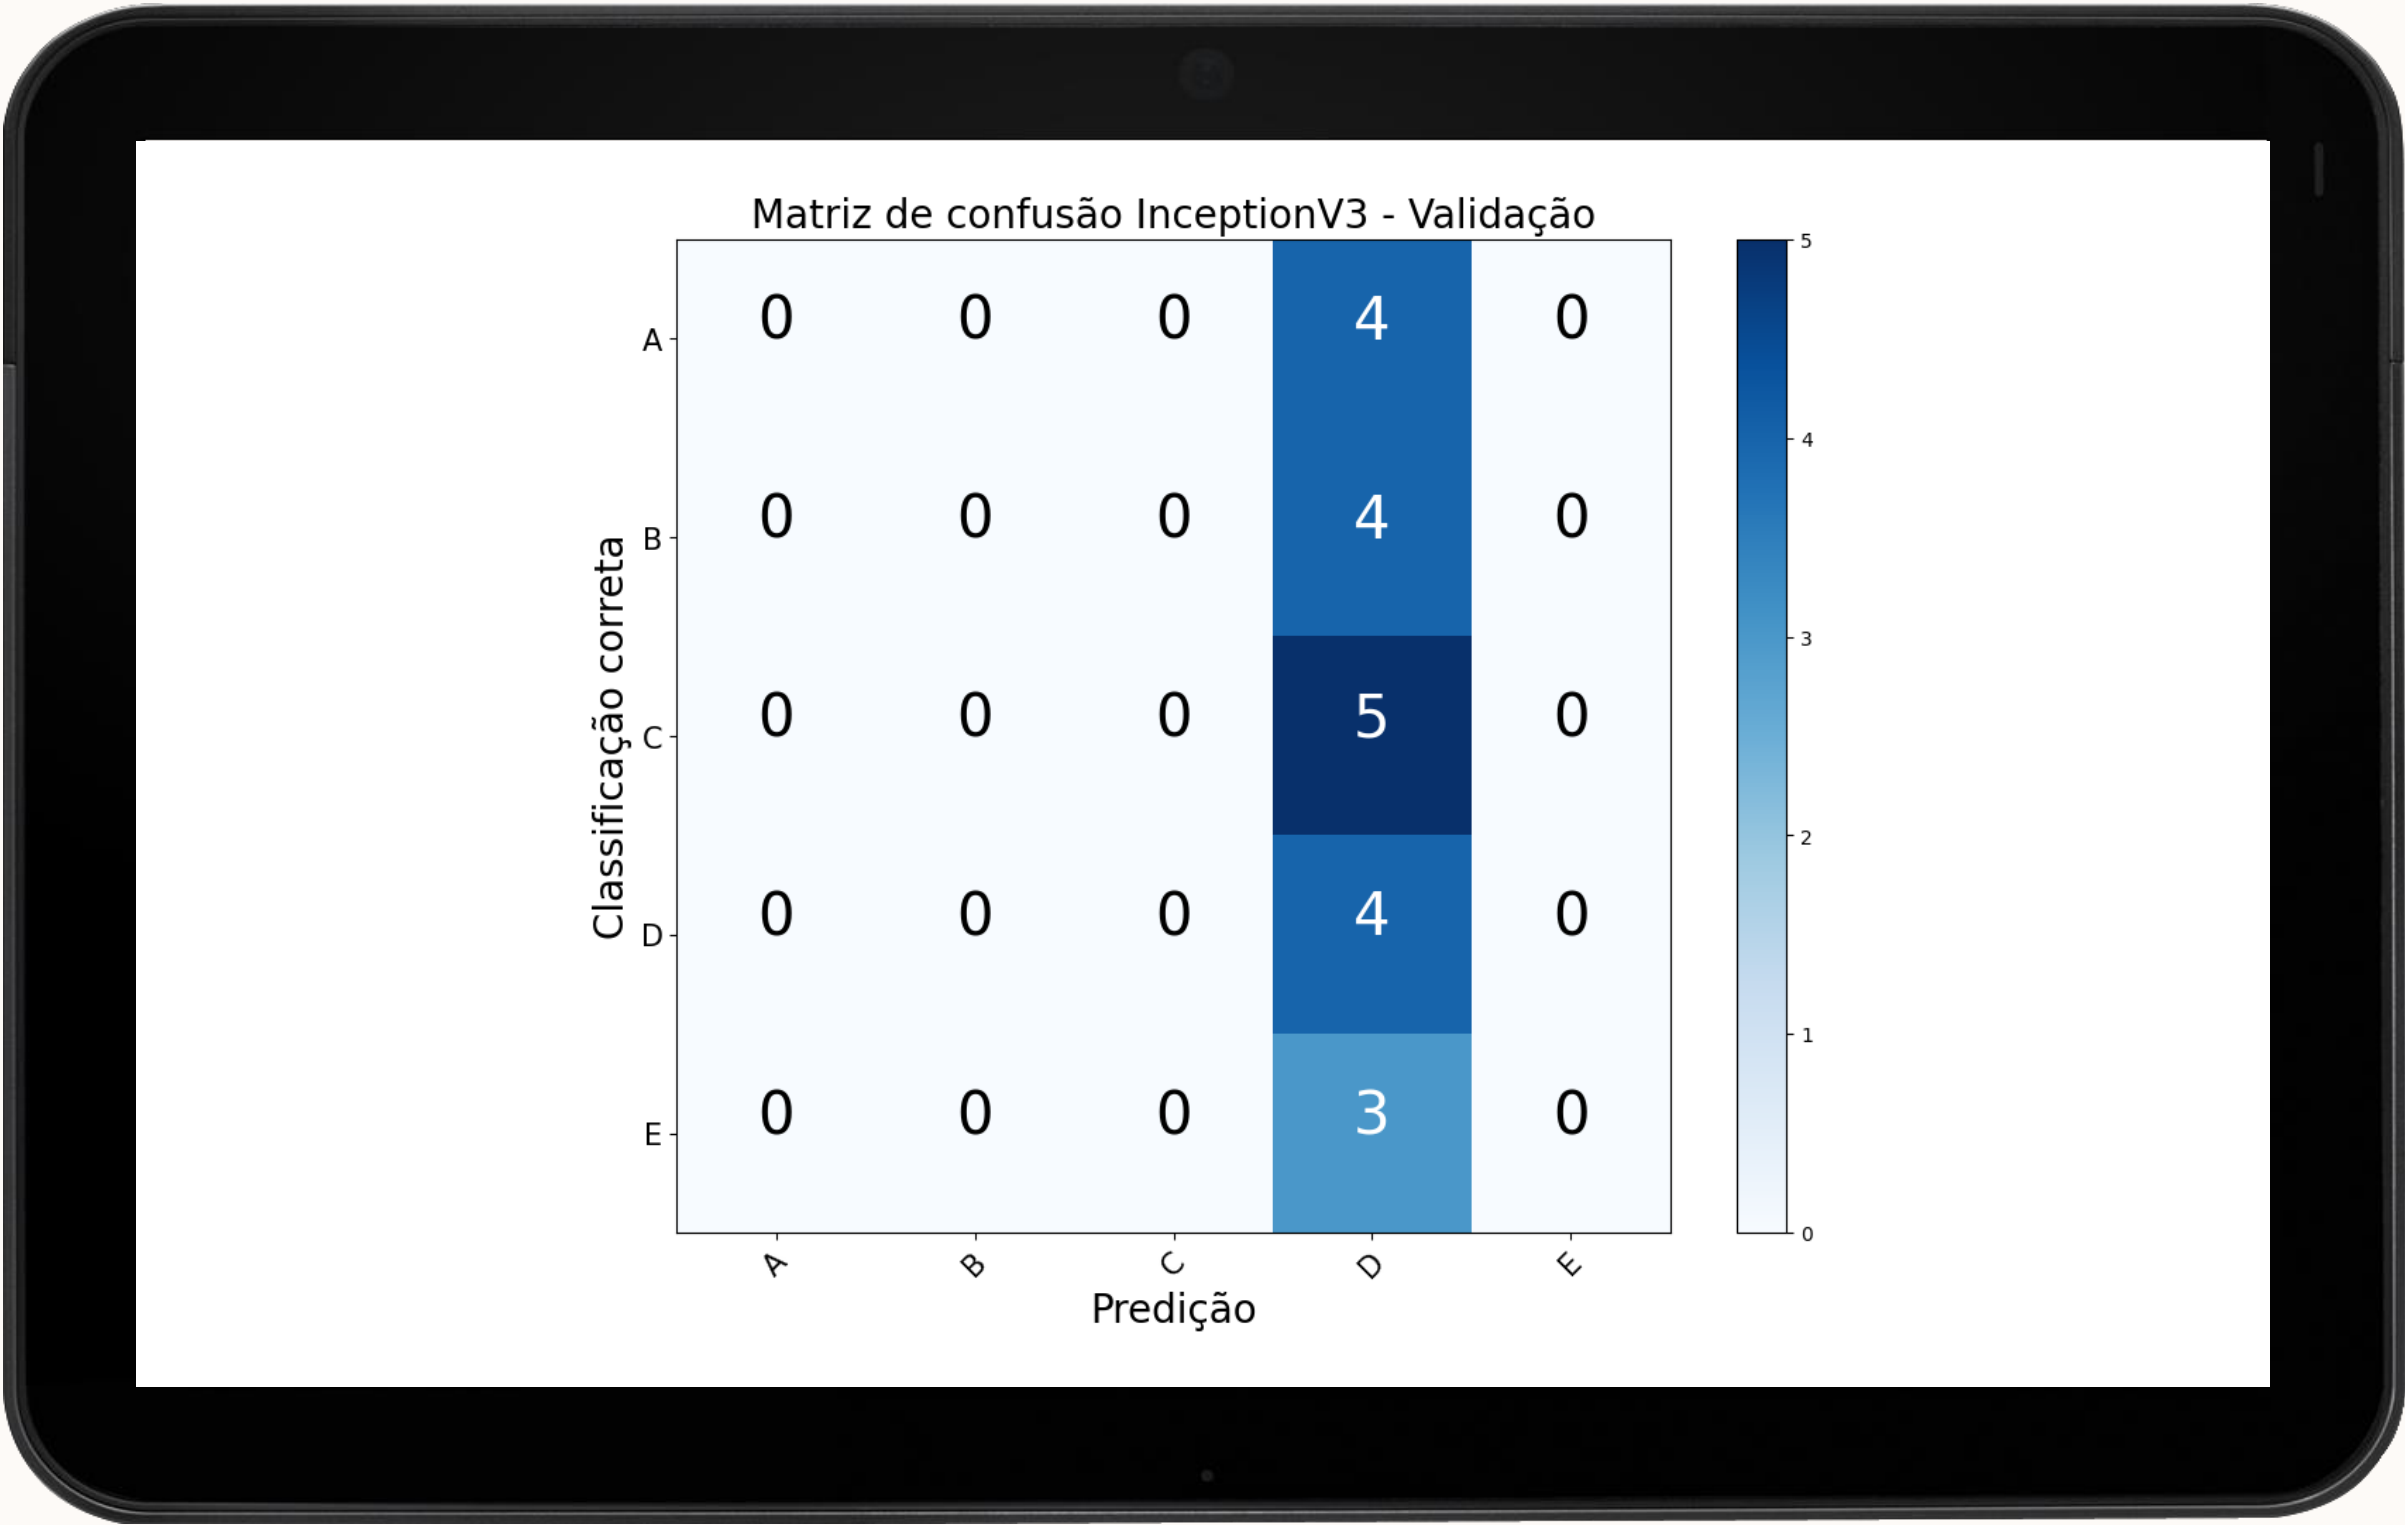
Precisão: 93%



InceptionV3:



InceptionV3 :

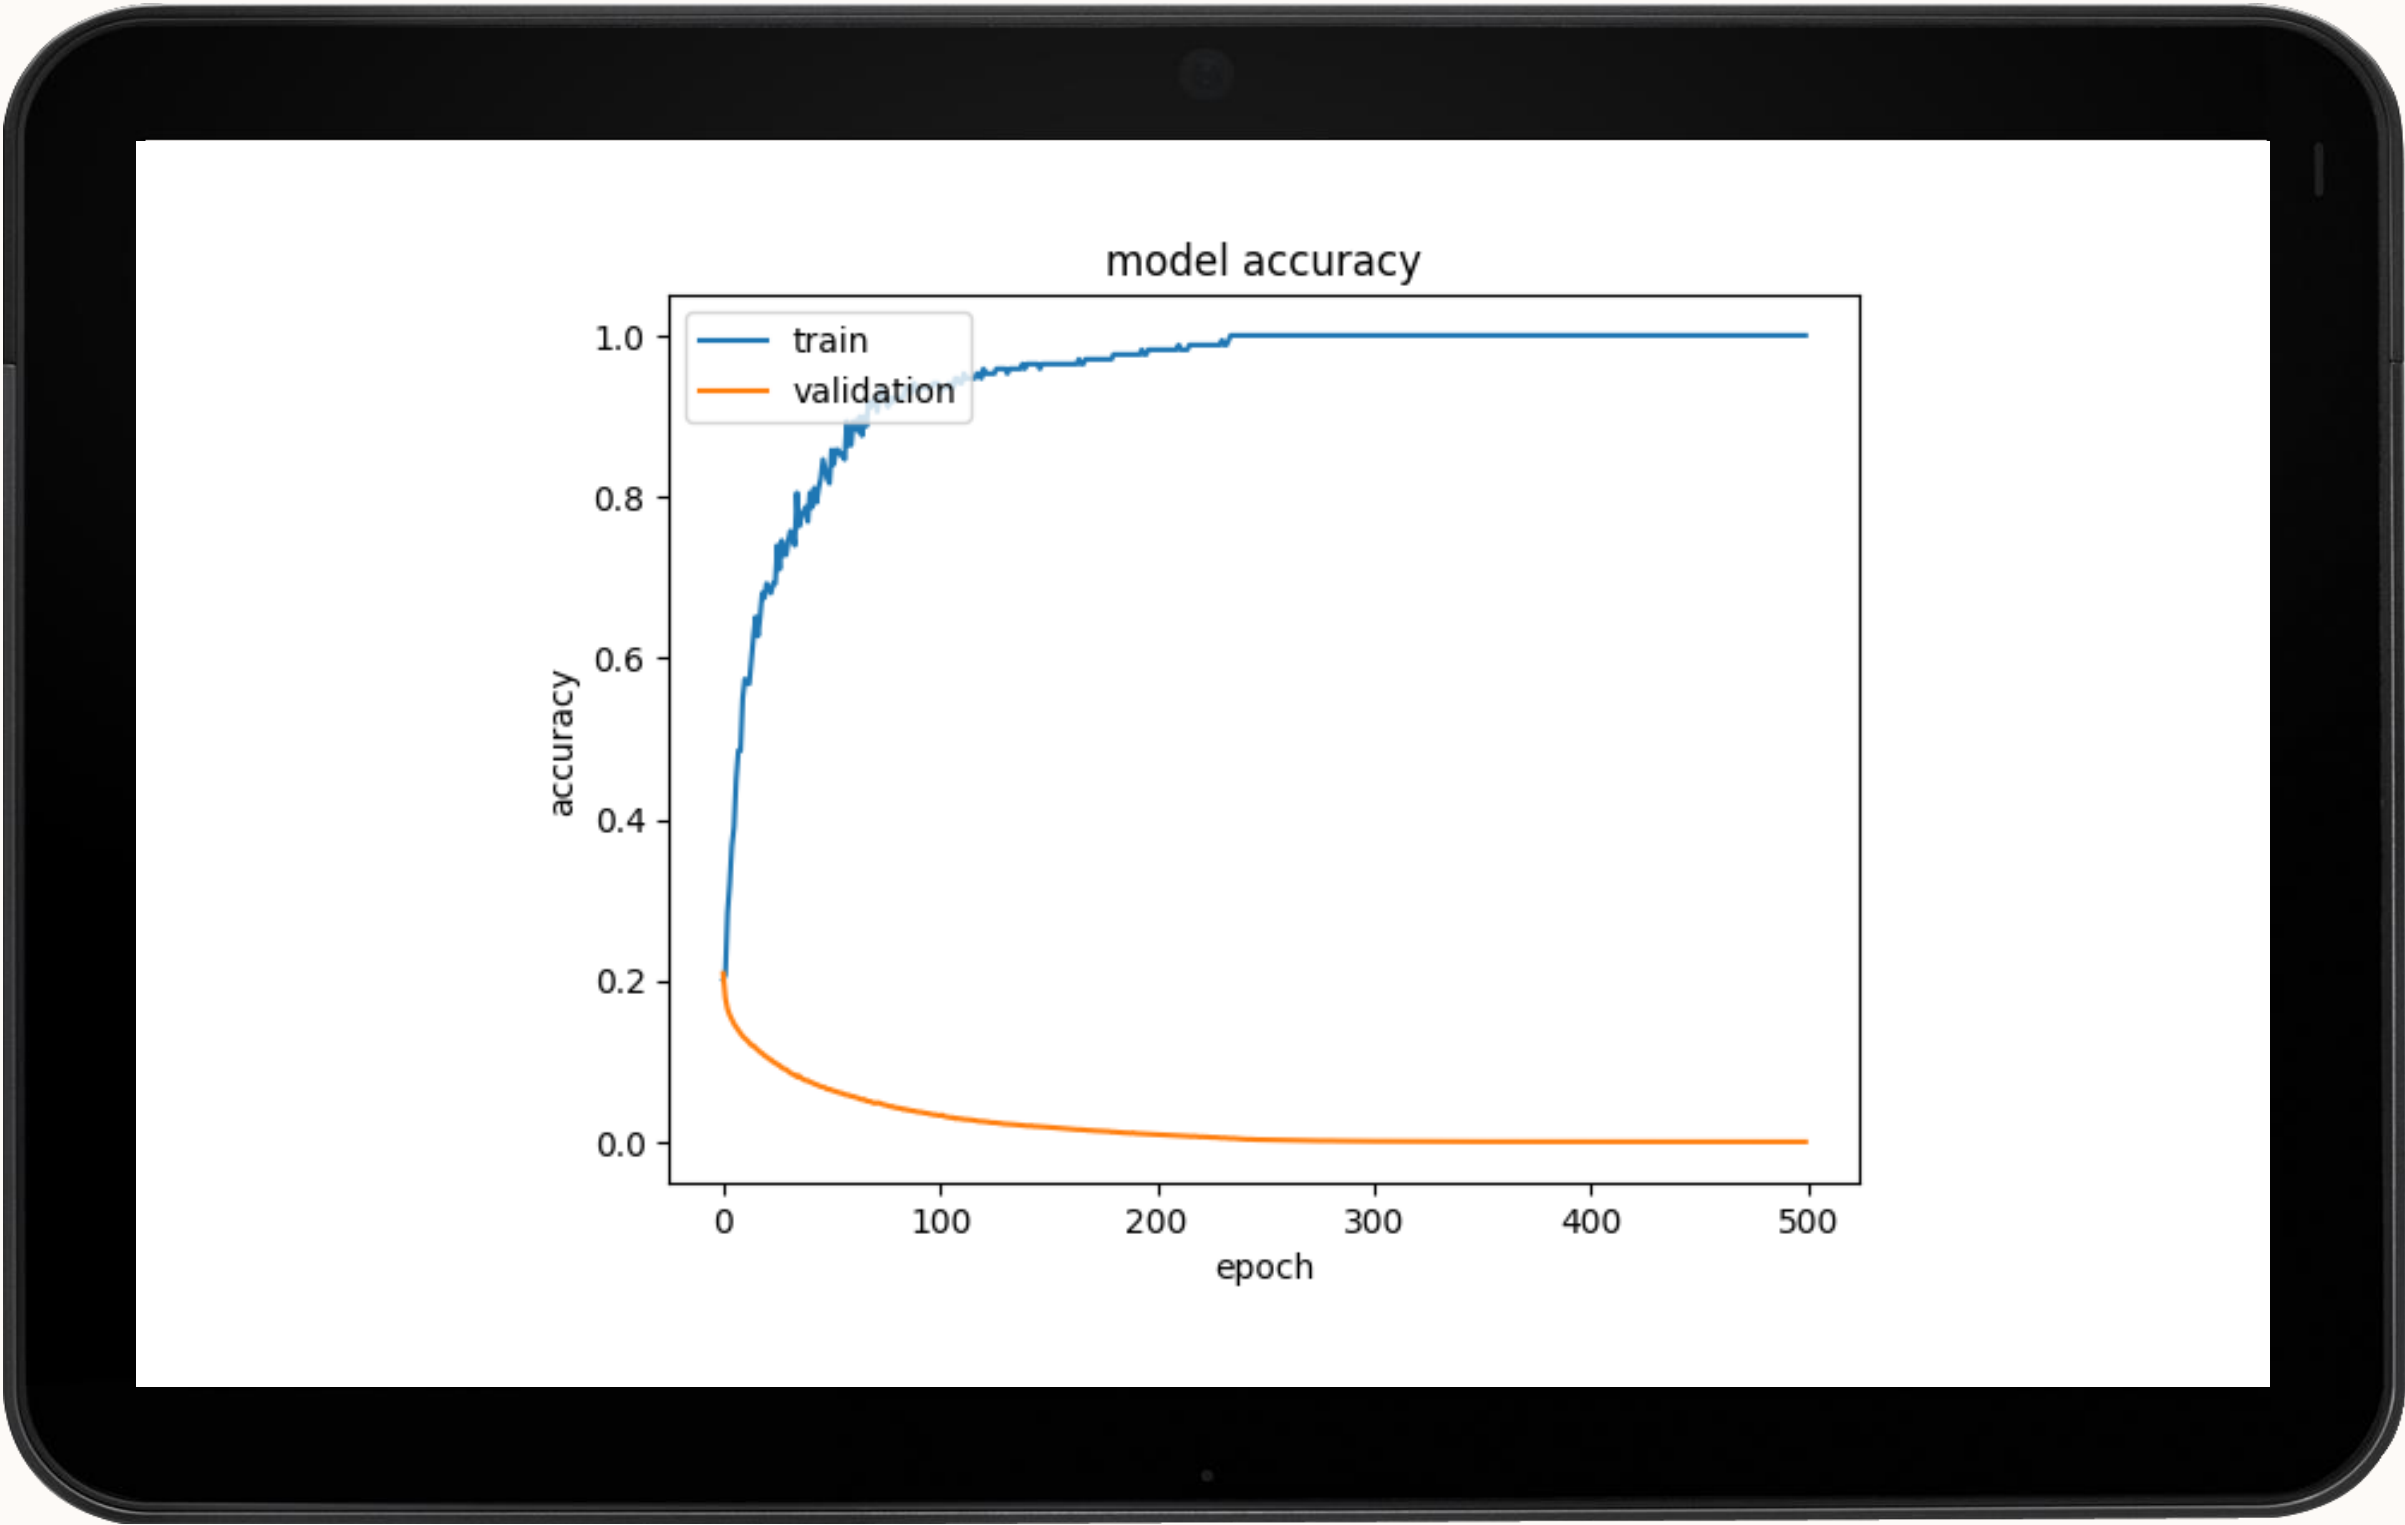


InceptionV3 :

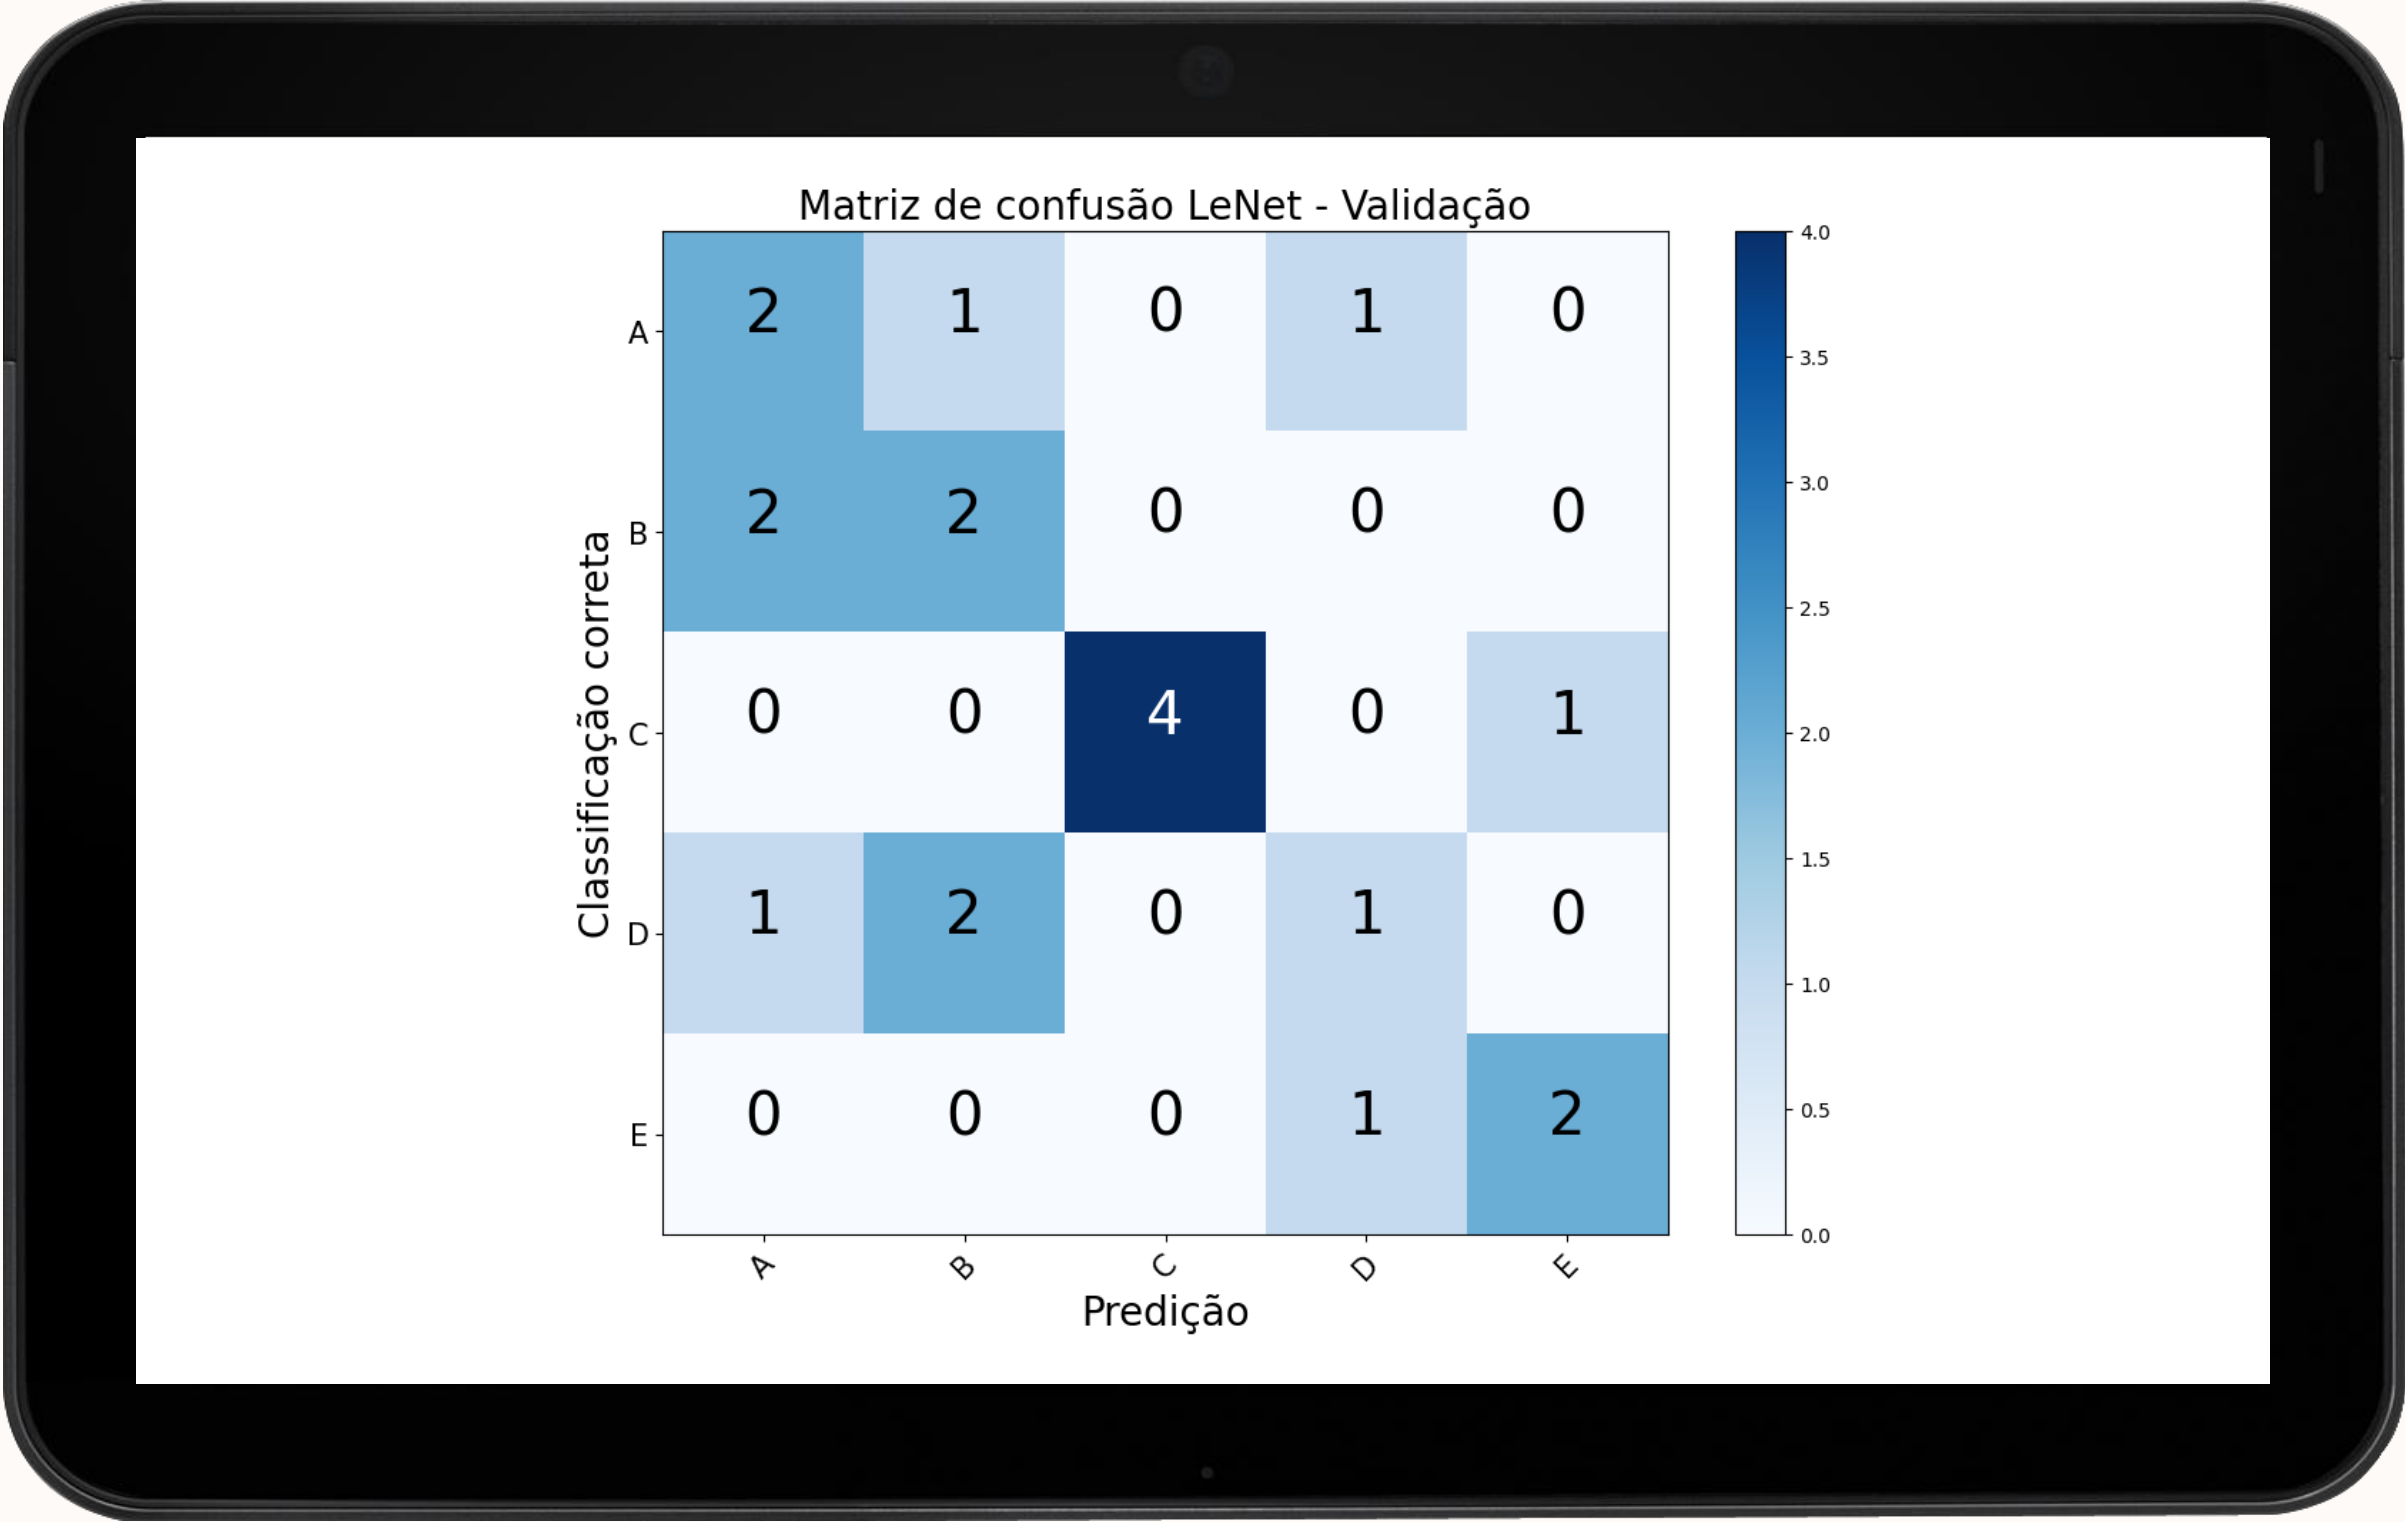
Acurácia: 20%

Precisão: 4%

LeNet:



LeNet:



LeNet:

Acurácia: 55%

Precisão: 55.9%

API:

Rota 1: upload de imagens

Rota 2: predição

Rota 3: gabarito

Rota 4: resultados



# Conclusão



Neste trabalho foi avaliado o uso de quatro redes convolucionais e técnicas de pré-processamento para se desenvolver um classificador robusto e com alta precisão. Através dos experimentos, a rede EfficientNetB0 se mostrou com os melhores resultados de acurácia e precisão, junto com a configuração de pré-processamento 'Filtro Gaussiano + Binarização'.

# Dúvidas?

Contato:

[iagomagalhaes23@gmail.com](mailto:iagomagalhaes23@gmail.com)

[vanessacarvalho@alu.ufc.br](mailto:vanessacarvalho@alu.ufc.br)